# 乳腺超声 v7：云端补充实验执行报告

三项事后验证已在当前 Codex 云端主机完成。它们围绕同一贡献补充证据：开发集锁定的数值阈值和测试队列中的等复核量排序，回答不同的部署问题；方法比较随决策规则和复核预算变化。

## 本轮能够回答什么

| 审稿关注 | 本轮执行 | 可用于论文的结果 |
| --- | --- | --- |
| **规则与排序的区别是否依赖 20%单点** | 8 个预算 × 两种规则 × 两个队列 | 完整预算响应及阈值迁移后的实际复核量 |
| **方向反转对阈值和抽样是否稳定** | 3 条 bootstrap 路线，各 10,000 次 | 分开呈现校准变异与测试抽样变异 |
| **良恶性构成是否对应队列差异** | 对称分解、直接标准化、5,000 次 bootstrap | 把构成相关项与层内率项作描述性分账 |

## 主要结果

完整预算扫描中没有一种方法始终检出更多低质量掩膜。外部队列 20%目标下，迁移阈值的 B−A 检出率差为 +18.75 个百分点，等复核 50 例时为 −6.25 个百分点；这种方向反转并未覆盖全部预算。

同时重采样开发集与测试队列时，原方向严格反转出现 3,094/10,000 次（30.94%）；任一差值为零占 28.08%。这些是当前样本的经验重采样频率，不能解释为总体概率或 p 值。

A 的外部减内部复核率差为 −6.56 个百分点，描述性分解为构成相关 +0.64 与层内率 −7.20 个百分点。按良恶性标准化后，该差异仍为负；这不是对设备、标注或提示框因素的因果排除。

## 范围与实际资源

使用冻结的 213 例开发、851 例内部、252 例外部逐例评分；低质量定义仍为参考 Dice <0.70。外部低质量独立病例仍为 16 例。原 H1–H3、阈值和逐例评分均保留。三项计算没有执行模型训练或推理，也没有新增患者。

主机 CPU 配额 2 核，内存上限 8 GiB；未发现 GPU、PyTorch 或精确 SAM 检查点。三项分析分别实际耗时约 1.07、5.91、2.83 秒（含各自导出/作图端点，互不相加为总墙钟时间）；不包含设计、代码审查或报告制作。

## 1. 全预算迁移与等复核量比较

目标预算固定为 5%、10%、15%、20%、25%、30%、40%、50%。每个数值阈值只用开发集风险分数校准：risk≥cutoff、同分全纳入、选择最接近目标的可实现复核量，等距时取较少者；随后原样迁移到测试队列。等复核量另按队列内风险排序选 K 例，不重新拟合数值阈值。

| 目标 | 阈值复核 A/B | 阈值检出 A/B | 差值 pp | 等量 K | 等量检出 A/B | 差值 pp |
|---|---|---|---|---|---|---|
| **5%** | 17/13 | 8/10 | +12.50 | 13 | 7/10 | +18.75 |
| **10%** | 24/23 | 9/12 | +18.75 | 25 | 9/12 | +18.75 |
| **15%** | 32/29 | 10/12 | +12.50 | 38 | 11/13 | +12.50 |
| **20%** | 35/33 | 10/13 | +18.75 | 50 | 14/13 | -6.25 |
| **25%** | 49/39 | 14/13 | -6.25 | 63 | 14/14 | +0.00 |
| **30%** | 64/46 | 14/13 | -6.25 | 76 | 14/14 | +0.00 |
| **40%** | 94/71 | 14/14 | +0.00 | 101 | 14/14 | +0.00 |
| **50%** | 129/97 | 15/14 | -6.25 | 126 | 15/15 | +0.00 |

表中复核分母均为 252 例，检出分母均为 16 例；差值均为 B−A。完整内部/外部 64 行结果及配对 Newcombe 区间见 CSV。所有预算一并报告，不用此网格选择有利预算。

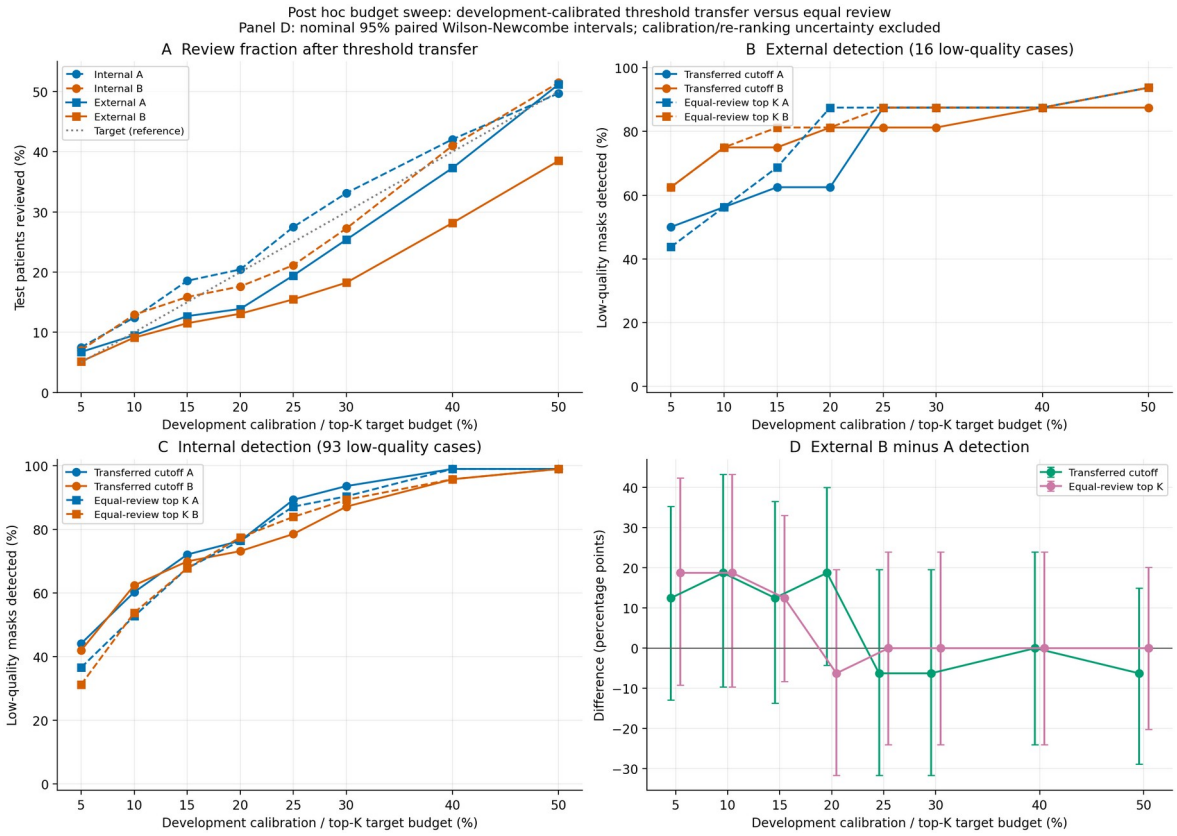



**图 1. 数值阈值迁移与等复核量规则的完整预算响应。**

20%开发阈值精确复现为 A=0.13705134391784668、B=0.06972856653991777，均复核 43/213 例。外部实际复核率为 13.89%与 13.10%，较名义 20%分别少 6.11、6.90 个百分点。

## 2. 阈值、抽样与排序的 bootstrap 稳定性

种子 20261106，PCG64；每条路线 10,000 次。开发、内部、外部各自独立作患者级有放回抽样，患者的 A/B 评分与质量标签始终配对。重复抽中的患者记录全部保留。路线间共享相关抽样，以分开呈现校准与测试抽样变异。

| 路线 | 变化部分 | 原方向严格反转 | 任一差值为零 |
|---|---|---|---|
| **1 固定阈值** | 只重采样两个测试队列 | 3,961/10,000 (39.61%) | 25.19% |
| **2 校准变异** | 只重采样开发集并重校准 | 9,040/10,000 (90.40%) | 4.35% |
| **3 全部重采样** | 开发集重校准＋测试队列抽样 | 3,094/10,000 (30.94%) | 28.08% |

“原方向严格反转”定义为外部固定阈值 B−A>0 且等复核 50 例 B−A<0，零差值不计入。路线 3 反向反转占 0.90%，同向且非零占 40.08%。每条路线联合有效 10,000 次。

| 路线 3 终点 | 原始点估计 pp | 百分位 95%区间 pp |
|---|---|---|
| **A 检出率：外部−内部** | -13.84 | [-39.03, +11.71] |
| **A 复核率：外部−内部** | -6.56 | [-12.70, -1.55] |
| **外部固定阈值检出率：B−A** | +18.75 | [-13.33, +37.50] |
| **外部等复核 50 例检出率：B−A** | -6.25 | [-25.00, +21.43] |

## 关键解释：经验支持约束

原外部低质量病例中，固定阈值下 10 例两者都检出、0 例仅 A 检出、3 例仅 B 检出、3 例均漏检。路线 1 无法从这些记录中生成“仅 A 检出”的未观测病例，因此其固定阈值 B−A 差值被结构性限制为非负，百分位区间[0,+40]不能用于排除总体中的 A 优势。原 H3 配对 Newcombe 区间[−4.28,+40.04]个百分点继续保留，不以 bootstrap 替换。

路线 2 的等复核 50 例差值恒为−6.25 个百分点，因为测试队列与排序均未变化。其 90.40%反转频率只描述给定测试病例时的校准敏感性。路线 3 的 30.94%也不是“反转为真”的概率。区间跨零不构成等效性证据。

本轮没有发生低质量总分母为零的抽样；实现已独立测试 NA 分支。同分排序使用原 patient_id 字符串，随后按抽样出现序号破同分；从不去重。

## 2.1 三条重采样路线的结果图

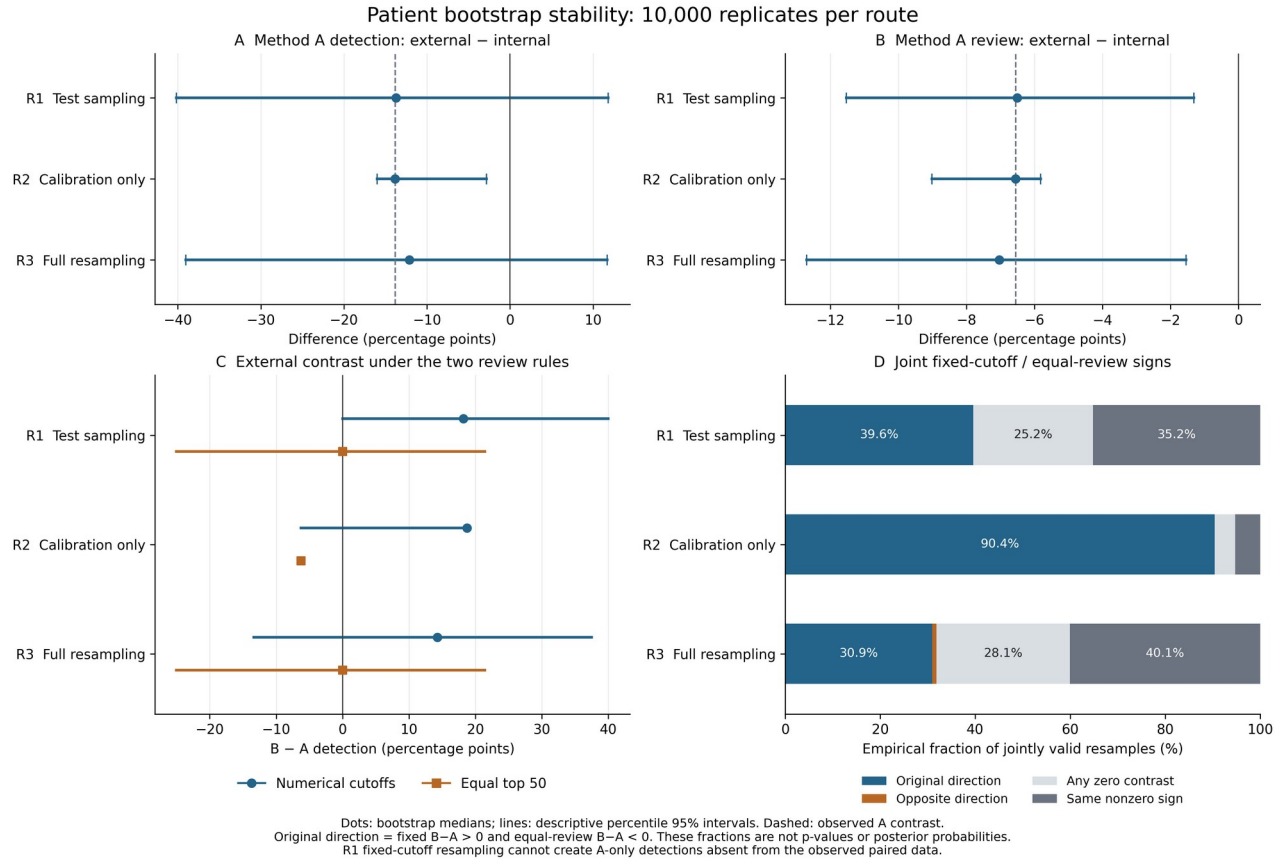



**图 2. 描述性百分位区间与经验符号组合。路线 1 存在未观测 A-only 病例无法生成的支持约束。**

## 可写入补充材料的英文结果段落

Across the complete budget grid, the relative detection yield depended on the review rule and target budget. In 10,000 joint development-and-test patient bootstrap replicates, the original strict direction pattern (external B-minus-A detection positive under transferred cutoffs and negative under equal-top50 review) occurred in 30.94%; at least one contrast was zero in 28.08%. These empirical resampling frequencies characterize the observed-sample sensitivity and are not population probabilities. The original prespecified Newcombe intervals were retained.

写作建议：以完整预算响应支持“决策规则决定比较含义”的主线，用 bootstrap 呈现其样本敏感性。主文保留原预设分析，新结果明确标注为事后探索性补充，避免把 20%处的方向反转提升为普遍规律。

## 3. 诊断构成标准化与对称分解

在原锁定阈值下，对数据集报告的良性/恶性标签作两层分解（并非所有病例均经组织病理确认）。内部低质量 53/40 例，外部 8/8 例。检出率的构成权重使用低质量病例中的良恶性份额 F 层/F；复核率的权重使用全队列份额 N 层/N。

对称 Kitagawa 恒等式：外部−内部差异 = Σ(w 外−w 内)(p 外+p 内)/2 + Σ(p 外−p 内)(w 外+w 内)/2。两项分别称“构成相关项”和“层内率项”；共同权重(w 外+w 内)/2 的直接标准化差值等于层内率项。

| 终点 | 总体差异 pp [95%] | 构成相关项 pp [95%] | 层内率项 pp [95%] |
|---|---|---|---|
| **A 检出率** | -13.84 [-40.85, +11.40] | -1.62 [-10.89, +5.73] | -12.23 [-39.94, +14.30] |
| **B 检出率** | +8.13 [-15.09, +28.18] | -0.78 [-6.43, +3.62] | +8.91 [-14.32, +28.70] |
| **A 复核率** | -6.56 [-11.54, -1.31] | +0.64 [-0.01, +1.54] | -7.20 [-12.15, -2.08] |
| **B 复核率** | -4.53 [-9.31, +0.41] | +0.79 [-0.01, +1.80] | -5.32 [-10.03, -0.56] |

5,000 次患者 bootstrap，种子 20261107；每次重算权重和层内率。检出率分解 4,999 次有效，另 1 次因外部良性低质量分母为零记 NA；总体检出率和复核率均 5,000 次有效。恒等式最大绝对残差≤$2.5\times10^{-16}$（原始比例）。

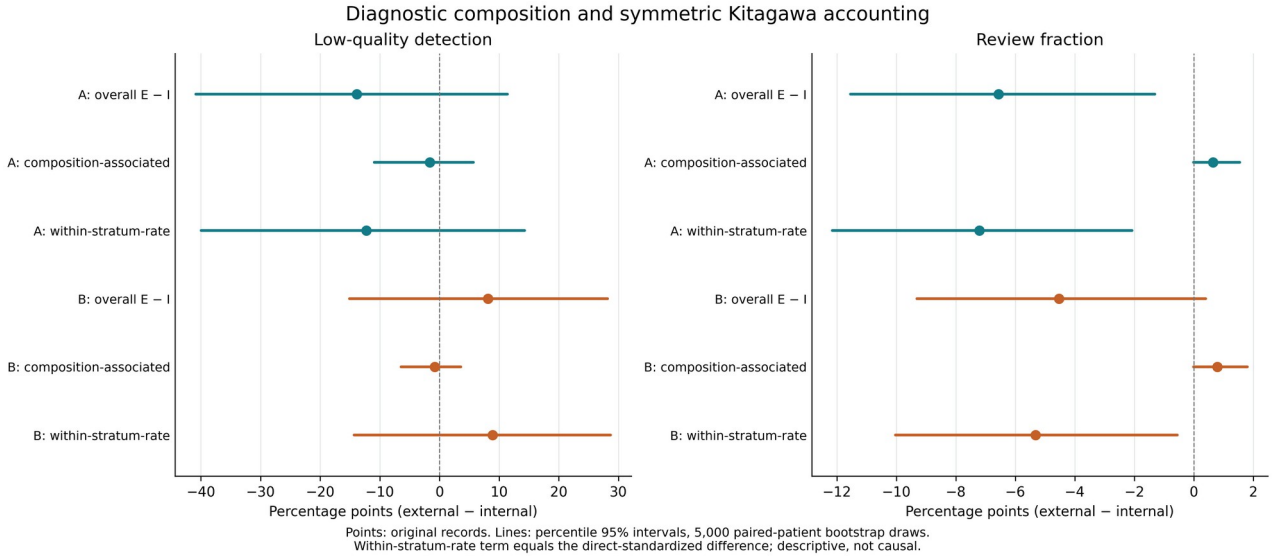



**图 3. 良恶性两层构成的描述性分账与共同权重标准化。**

A 检出率差−13.84 = −1.62−12.23 个百分点；A 复核率差−6.56 = +0.64−7.20 个百分点。两项是观察到的率与权重的代数分账，不能称为“病理导致的比例”或因果解释百分比，也不能排除设备、采集、标注和提示框差异。

## 4. 后续模型实验的可执行性与优先级

| 实验 | 执行条件与设计 | 当前状态 |
| --- | --- | --- |
| **六例漏检预测轮廓重放** | 使用原 SAM ViT-B 检查点、精确 SHA-256、原提示和模型源码；保存真实预测并复核评分一致性 | 本机缺精确权重，官方下载域名未获网络允许；未执行推理 |
| **提示框扰动敏感性** | 预先固定±5%、±10%、±20%扰动网格；锁定质量定义；对同一病例配对比较；每档重新记录运行时间 | 需模型环境/权重；合成扰动不等于独立操作者框验证 |
| **独立提示框验证** | 由独立操作者在不知道参考掩膜和预测的条件下给框，再用锁定规则验证 | 需要新增人工标注；当前原始框来自参考掩膜，不能自行宣称已完成 |
| **更大独立外部验证** | 新增独立患者，预先固定阈值/规则/主要终点，再一次性验证 | 需要新的真实队列；bootstrap 不能增加独立病例 |

六例重放的价值最高：直接回应审稿人对预测轮廓的要求。现有精确重放入口在 v7 的 Analysis 目录。检查点预期 SHA-256 为 ec2df62732614e57411cdcf32a23ffdf28910380d03139ee0f4fcbe91eb8c912。未用别的检查点、参考轮廓或其它已保存病例替代六例预测。

## 5. 复现、来源与交付说明

三项计算的源提交固定为 f9cfdc49b6e6a9e037443f6ce077006bc9377960。方案在本轮计算前固定，性质为事后探索性，不是原研究预注册。方案 SHA-256：c34718732b856ab31d0d8ae19c88bbbf0f43a9614ea14433d8f62210cc1409c7。原字符串同分规则及整数预算的说明见 clarification_addendum.json。

Python 3.12.14、NumPy 2.3.5、Matplotlib 3.10.8、openpyxl 3.1.5；单进程，数值线程设为 1。逐输入与脚本哈希、全部 bootstrap 记录、有效次数、运行端点和独立复核记录随包交付。两份大 CSV 在归档版采用 gzip 无损压缩，原始 CSV 的 SHA-256 另存。

复现时使用 README 中的独立 git worktree 固定上述源提交，再向新输出目录运行三个脚本。不要在最新 main 上直接覆盖原记录；脚本会检查源提交与输入哈希。ZIP 不打包原始影像或模型权重，所需来源与条款沿用仓库 data 及 reproducibility 说明。

通讯元数据：按作者本轮明确确认，两位作者均采用重庆医科大学缙云校区人工智能医学学院、大学城中路 61 号兰园 6 号楼、邮编 400016。官方来源中的 401331 作为历史证据保留，当前作者通讯邮编以本次确认 400016 为准。

本报告用于作者审阅和后续整合。本轮未把新分析改为原预设主要终点，也未执行期刊投稿。